

# 运筹学习题课

侯馨翔

2021 年 12 月 14 日

## 1 拟牛顿法收敛性

### 1.1 拟牛顿法的全局收敛性

BFGS格式:

$$B_{k+1} = B_k + \frac{y_k y_k^T}{s_k^T y_k} - \frac{B_k s_k (B_k s_k)^T}{(s_k)^T B_k s_k} \quad (1.1)$$

定义 1.1 (Wolfe 准则). 设  $d_k$  是点  $x_k$  处的下降方向, 若

$$f(x_k + \alpha d_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T d_k \quad (1.2)$$

$$\nabla f(x_k + \alpha d_k)^T d_k \geq c_2 \nabla f(x_k)^T d_k \quad (1.3)$$

则称步长  $\alpha$  满足 Wolfe 准则, 其中  $c_1, c_2 \in (0, 1)$  为给定的常数且  $c_1 < c_2$ .

定理 1.1 (Zoutendijk). 考虑一般的迭代格式

$$x_{k+1} = x_k + \alpha_k d_k, \quad (1.4)$$

其中  $d_k$  是搜索方向,  $\alpha_k$  是步长, 且在迭代过程中 Wolfe 准则满足. 假设目标函数  $f$  下有界、连续可微且梯度  $L$ -Lip 连续, 即

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y \in \mathbb{R}^n,$$

那么

$$\sum_{k=1}^{\infty} \cos^2 \theta_k \|\nabla f(x_k)\|^2 < +\infty, \quad (1.5)$$

其中  $\cos \theta_k$  为负梯度  $-\nabla f(x_k)$  和下降方向  $d_k$  夹角的余弦, 即

$$\cos \theta_k = \frac{-\nabla f(x_k)^T d_k}{\|\nabla f(x_k)\| \|d_k\|}$$

不等式 (1.5) 也被称为 Zoutendijk 条件

证明. 由条件 1.3,

$$(\nabla f(x_{k+1}) - \nabla f(x_k))^T d_k \geq (c_2 - 1) \nabla f(x_k)^T d_k.$$

由柯西不等式和梯度  $L - Lip$  连续性质,

$$(\nabla f(x_{k+1}) - \nabla f(x_k))^T d_k \leq \|\nabla f(x_{k+1}) - \nabla f(x_k)\| \|d_k\| \leq \alpha_k L \|d_k\|^2.$$

结合上述两式可得

$$\alpha_k \geq \frac{c_2 - 1}{L} \frac{\nabla f(x_k)^T d_k}{\|d_k\|^2}.$$

注意到  $\nabla f(x_k)^T d_k < 0$ , 将上式代入条件 1.2, 则

$$f(x_{k+1}) \leq f(x_k) + c_1 \frac{c_2 - 1}{L} \frac{(\nabla f(x_k)^T d_k)^2}{\|d_k\|^2}.$$

根据  $\theta_k$  的定义, 此不等式可等价表述为

$$f(x_{k+1}) \leq f(x_k) + c_1 \frac{c_2 - 1}{L} \cos^2 \theta_k \|\nabla f(x_k)\|^2.$$

再关于  $k$  求和, 我们有

$$f(x_{k+1}) \leq f(x_0) - c_1 \frac{1 - c_2}{L} \sum_{j=0}^k \cos^2 \theta_j \|\nabla f(x_j)\|^2.$$

又因为函数  $f$  是下有界的, 且由  $0 < c_1 < c_2 < 1$  可知  $c_1(1 - c_2) > 0$ , 因此当  $k \rightarrow \infty$  时,

$$\sum_{j=1}^{\infty} \cos^2 \theta_j \|\nabla f(x_j)\|^2 < +\infty.$$

□

**定理 1.2.** 设  $x, y, u, v \in \mathbb{R}^n$ , 则

$$\det(I_{n \times n} + xy^T + uv^T) = (1 + y^T x)(1 + v^T u) - (x^T v)(y^T u). \quad (1.6)$$

证明. 利用降阶公式可得:

$$\begin{aligned} \det(I_{n \times n} + xy^T + uv^T) &= \det \left( I_{n \times n} + \begin{pmatrix} x & u \end{pmatrix} \begin{pmatrix} y^T \\ v^T \end{pmatrix} \right) \\ &= \det \left( I_{2 \times 2} + \begin{pmatrix} x^T \\ u^T \end{pmatrix} \begin{pmatrix} y & v \end{pmatrix} \right) \end{aligned}$$

□

**定理 1.3** (BFGS全局收敛性). 假设初始矩阵  $B^0$  是对称正定矩阵, 目标函数  $f(x)$  是二阶连续可微函数, 且下水平集

$$\mathcal{L} = \{x \in \mathbb{R}^n | f(x) \leq f(x_0)\} \quad (1.7)$$

是凸的, 并且存在整数  $m$  以及  $M$  使得对于任意的  $z \in \mathbb{R}^n$  以及任意的  $x \in \mathcal{L}$  有

$$m\|z\|^2 \leq z^T \nabla^2 f(x) z \leq M\|z\|^2 \quad (1.8)$$

则采用 BFGS 格式并结合 Wolfe 线搜索的拟牛顿算法全局收敛到  $f(x)$  的极小值点  $x^*$ .

证明. 为了方便, 定义

$$m_k = \frac{y_k^T s_k}{s_k^T s_k}, \quad M_k = \frac{y_k^T y_k}{y_k^T s_k}.$$

由 1.8 以及  $y_k = \int_0^1 \nabla^2 f(x_k + t(x_{k+1} - x_k)) s_k dt$  可得

$$m_k \geq m, \quad M_k \leq M. \quad (1.9)$$

根据 1.1, 可得

$$\text{Tr}(B_{k+1}) = \text{Tr}(B_k) - \frac{\|B_k s_k\|^2}{s_k^T B_k s_k} + \frac{\|y_k\|^2}{y_k^T s_k} \quad (1.10)$$

又由 1.2, 可得

$$\det B_{k+1} = \det B_k \frac{y_k^T s_k}{s_k^T B_k s_k} \quad (1.11)$$

定义

$$\cos \theta_k = \frac{s_k^T B_k s_k}{\|s_k\| \|B_k s_k\|}, \quad q_k = \frac{s_k^T B_k s_k}{s_k^T s_k},$$

那么将1.10整理可得

$$\frac{\|B_k s_k\|^2}{s_k^T B_k s_k} = \frac{\|B_k s_k\|^2 \|s_k\|^2 s_k^T B_k s_k}{(s_k^T B_k s_k)^2 \|s_k\|^2} = \frac{q_k}{\cos^2 \theta_k} \quad (1.12)$$

同样由1.11可得

$$\det B_{k+1} = \det B_k \frac{y_k^T s_k}{s_k^T s_k} \frac{s_k^T s_k}{s_k^T B_k s_k} = \det B_k \frac{m_k}{q_k}$$

引进矩阵辅助函数

$$\psi(B) = \text{Tr}(B) - \ln \det B,$$

则我们有

$$\begin{aligned} \psi(B_{k+1}) &= \text{Tr}(B_k) + M_k - \frac{q_k}{\cos^2 \theta_k} - \ln \det B_k - \ln m_k + \ln q_k \\ &= \psi(B_k) + (M_k - \ln m_k - 1) + (1 - \frac{q_k}{\cos^2 \theta_k} + \ln \frac{q_k}{\cos^2 \theta_k}) + \ln \cos^2 \theta_k. \end{aligned} \quad (1.13)$$

根据1.13, 以及 $\psi(B) > 0, 1 - t + \ln t \leq 0, \forall t$ 可以得到

$$0 < \psi(B_{k+1}) \leq \psi(B_0) + (k+1)c + \sum_{j=0}^k \ln \cos^2 \theta_j. \quad (1.14)$$

其中,  $c = M - \ln m - 1$ 。不妨假设 $c > 0$ 。注意到 $s_k = -\alpha_k(B_k)^{-1} \nabla f(x_k)$ 是搜索方向, 那么 $\cos \theta_k$ 即是搜索方向与梯度方向夹角余弦。根据定理1.1可知 $\|\nabla f(x_k)\|$ 大于某个非零常数仅当 $\cos \theta_k \rightarrow 0$ 。因此, 为了证明 $\|\nabla f(x_k)\| \rightarrow 0$ , 我们仅需证明 $\cos \theta_k \rightarrow 0$ 不成立。

反证法: 假设 $\cos \theta_k \rightarrow 0$ , 那么存在 $k_1 > 0$ , 对于任意的 $j > k_1$ ,

$$\ln \cos^2 \theta_j < -2c.$$

结合1.14, 当 $k > k_1$ 时,

$$\begin{aligned} 0 < \psi(B_{k+1}) &\leq \psi(B_0) + (k+1)c + \sum_{j=1}^{k_1} \ln \cos^2 \theta_j + \sum_{j=k_1}^k (-2c) \\ &= \psi(B_0) + \sum_{j=0}^{k_1} \ln \cos^2 \theta_j + 2ck_1 + C - ck. \end{aligned} \quad (1.15)$$

上式右边对于充分大的 $k$ 是负的，而不等式左边是0，矛盾。因此存在一个子列 $\{j_k\}_{k=1,2,\dots}$ 使得 $\cos \theta_{j_k} \geq \delta > 0$ 。根据定理1.1，可以得到 $\liminf_{k \rightarrow \infty} \|\nabla f(x_k)\| \rightarrow 0$ 。又因为问题对 $x \in \mathcal{L}$ 是强凸的，所以有 $x_k \rightarrow x^*$   $\square$

## 1.2 拟牛顿法超线性收敛速度

本节适用于一般非线性目标函数（不仅仅是凸函数）。首先我们需要一些额外的假设。

**定理 1.4.** 设 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 是二阶连续可微。考虑迭代步 $x_{k+1} = x_k + \alpha_k d_k$ ，其中 $d_k$ 是下降方向，当 $c_1 \leq 1/2$ 时 $\alpha_k$ 满足Wolfe条件。若 $\{x_k\}$ 收敛到点 $x^*$ 使得 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*)$ 时正定的，并且满足

$$\liminf_{k \rightarrow \infty} \frac{\|\nabla f(x_k) + \nabla^2 f(x_k) d_k\|}{\|d_k\|} = 0 \quad (1.16)$$

则

(1) 对于 $k > k_0$ 的步长取 $\alpha_k = 1$

(2) 若 $\alpha_k = 1 \quad \forall k > k_0$ ， $\{x_k\}$ 超线性收敛至 $x^*$ 。

若 $d_k$ 是拟牛顿搜索方向，那么1.16等价于

$$\liminf_{k \rightarrow \infty} \frac{\|(B_k - \nabla^2 f(x^*))d_k\|}{\|d_k\|} = 0. \quad (1.17)$$

首先，我们记

$$\sum_{k=1}^{\infty} \|x_k - x^*\| < \infty \quad (1.18)$$

**假设 1.1.** 海瑟矩阵 $G$ 在 $x^*$ 上Lipschitz连续，也就是说对于在 $x^*$ 附近的点 $x$ ，均满足

$$\|G(x) - G(x^*)\| \leq L\|x - x^*\|,$$

其中 $L$ 为一个正常数。

首先，我们有

$$\tilde{s}_k = G_*^{-1/2} s_k, \quad \tilde{y}_k = G_*^{-1/2} y_k, \quad \tilde{B}_k = G_*^{-1/2} B_k G_*^{-1/2},$$

其中  $G_* = G(x^*)$ 。我们定义

$$\cos \tilde{\theta}_k = \frac{\tilde{s}_k^T \tilde{B}_k \tilde{s}_k}{\|\tilde{s}_k\| \|\tilde{B}_k \tilde{s}_k\|}, \quad \tilde{q}_k = \frac{\tilde{s}_k^T \tilde{B}_k \tilde{s}_k}{\|\tilde{s}_k\|^2},$$

令

$$\tilde{M}_k = \frac{\|\tilde{y}_k\|^2}{\tilde{y}_k^T \tilde{s}_k}, \quad \tilde{m}_k = \frac{\tilde{y}_k^T \tilde{s}_k}{\tilde{s}_k^T \tilde{s}_k}$$

由BFGS的迭代公式可以得到

$$\tilde{B}_{k+1} = \tilde{B}_k - \frac{\tilde{B}_k \tilde{s}_k \tilde{s}_k^T \tilde{B}_k}{\tilde{s}_k^T \tilde{B}_k \tilde{s}_k} + \frac{\tilde{y}_k \tilde{y}_k^T}{\tilde{y}_k^T \tilde{s}_k}$$

由于这个表达式与BFGS的更新公式由相同的形式，那么由1.13同样地可得

$$\psi(\tilde{B}_{k+1}) = \psi(\tilde{B}_k) + (\tilde{M}_k - \ln \tilde{m}_k - 1) + \left[1 - \frac{\tilde{q}_k}{\cos^2 \tilde{\theta}_k} + \ln \frac{\tilde{q}_k}{\cos^2 \tilde{\theta}_k}\right] + \ln \cos^2 \tilde{\theta}_k. \quad (1.19)$$

而由  $y_k = G_k s_k$  可知

$$y_k - G_* s_k = (G_k - G_*) s_k$$

而且

$$\tilde{y}_k - \tilde{s}_k = G_*^{-1/2} (G_k - G_*) G_*^{-1/2} \tilde{s}_k.$$

由假设1.1可知

$$\|\tilde{y}_k - \tilde{s}_k\| \leq \|G_*^{-1/2}\|^2 \|\tilde{s}_k\| \|G_k - G_*\| \leq \|G_*^{-1/2}\|^2 \|\tilde{s}_k\| L \epsilon_k,$$

其中  $\epsilon_k = \max \{\|x^{k+1} - x^*\|, \|x_k - x^*\|\}$ 。所以我们可以得到

$$\frac{\|\tilde{y}_k - \tilde{s}_k\|}{\|\tilde{s}_k\|} \leq \bar{c} \epsilon_k, \quad (1.20)$$

其中  $\bar{c}$  为正常数。

**定理 1.5.** 设  $f$  为二阶连续可微并且在假设1.1下使用BFGS算法迭代收敛到最优点  $x^*$ 。假设1.18成立，那么  $x_k$  以超线性收敛速度收敛至  $x^*$ 。

证明. 由1.20我们有

$$\|\tilde{y}_k\| - \|\tilde{s}_k\| \leq \bar{c} \epsilon_k \|\tilde{s}_k\|, \quad \|\tilde{s}_k\| - \|\tilde{y}_k\| \leq \bar{c} \epsilon_k \|\tilde{s}_k\|,$$

因此

$$(1 - \bar{c} \epsilon_k) \|\tilde{s}_k\| \leq \|\tilde{y}_k\| \leq (1 + \bar{c} \epsilon_k) \|\tilde{s}_k\|. \quad (1.21)$$

由1.20和1.21, 我们有

$$(1 - \bar{c}\epsilon_k)^2 \|\tilde{s}_k\|^2 - 2\tilde{y}_k^T \tilde{s}_k + \|\tilde{s}_k\|^2 \leq \|\tilde{y}_k\|^2 - 2\tilde{y}_k^T \tilde{s}_k + \|\tilde{s}_k\|^2 \leq \bar{c}^2 \epsilon_k^2 \|\tilde{s}_k\|^2,$$

因此

$$2\tilde{y}_k^T \tilde{s}_k \geq (1 - 2\bar{c}\epsilon_k + \bar{c}^2 \epsilon_k + 1 - \bar{c}^2 \epsilon_k^2) \|\tilde{s}_k\|^2 = 2(1 - \bar{c}\epsilon_k) \|\tilde{s}_k\|^2.$$

由 $\tilde{m}_k$ 的定义可以得到

$$\tilde{m}_k = \frac{\tilde{y}_k^T \tilde{s}_k}{\|\tilde{s}_k\|^2} \geq 1 - \bar{c}\epsilon_k \quad (1.22)$$

那么由1.21和1.22可以得到

$$\tilde{M}_k = \frac{\|\tilde{y}_k\|^2}{\tilde{y}_k^T \tilde{s}_k} \leq \frac{1 + \bar{c}\epsilon_k}{1 - \bar{c}\epsilon_k} \quad (1.23)$$

由于 $x_k \rightarrow x^*$ , 我们有 $\epsilon_k \rightarrow 0$ , 由1.23存在一个正常数 $c > \bar{c}$ , 当 $k$ 足够大时

$$\tilde{M}_k \leq 1 + \frac{2\bar{c}}{1 - \bar{c}\epsilon_k} \epsilon_k \leq 1 + c\epsilon_k \quad (1.24)$$

我们利用函数 $h(t) = 1 - t + \ln t$ 的非正性, 我们有

$$\frac{-x}{1-x} - \ln(1-x) = h\left(\frac{1}{1-x}\right) \leq 0.$$

对充分大的 $k$ 我们可以假设 $\bar{c}\epsilon_k < \frac{1}{2}$ , 因此

$$\ln(1 - \bar{c}\epsilon_k) \geq \frac{-\bar{c}\epsilon_k}{1 - \bar{c}\epsilon_k} \geq -2\bar{c}\epsilon_k.$$

结合1.22可以得到

$$\ln \tilde{m}_k \geq \ln(1 - \bar{c}\epsilon_k) \geq -2\bar{c}\epsilon_k > -2c\epsilon_k \quad (1.25)$$

我们由1.19,1.24,1.25可得

$$0 < \psi(\tilde{B}_{k+1}) \leq \psi(\tilde{B}_k) + 3c\epsilon_k + \ln \cos^2 \tilde{\theta}_k + \left[1 - \frac{\tilde{q}_k}{\cos^2 \tilde{\theta}_k} + \ln \frac{\tilde{q}_k}{\cos^2 \tilde{\theta}_k}\right]. \quad (1.26)$$

由1.18可得

$$\sum_{j=0}^{\infty} \left( \ln \frac{1}{\cos^2 \tilde{\theta}_j} - \left[1 - \frac{\tilde{q}_j}{\cos^2 \tilde{\theta}_j} + \ln \frac{\tilde{q}_j}{\cos^2 \tilde{\theta}_j}\right] \right) \leq \psi(\tilde{B}_0) + 3c \sum_{j=0}^{\infty} \epsilon_j < +\infty.$$

由于 $\ln(1/\cos^2 \tilde{\theta}_j) \geq 0 \forall j$ , 我们可以得到

$$\lim_{j \rightarrow \infty} \ln \frac{1}{\cos^2 \tilde{\theta}_j} = 0, \quad \lim_{j \rightarrow \infty} \left(1 - \frac{\tilde{q}_j}{\cos^2 \tilde{\theta}_j} + \ln \frac{\tilde{q}_j}{\cos^2 \tilde{\theta}_j}\right) = 0,$$

这表明了

$$\lim_{j \rightarrow \infty} \cos \tilde{\theta}_j = 1, \quad \lim_{j \rightarrow \infty} \tilde{q}_j = 1 \quad (1.27)$$

由1.12我们有

$$\begin{aligned} \frac{\|G_*^{-1/2}(B_k - G_*)s_k\|^2}{\|G_*^{1/2}s_k\|^2} &= \frac{\|(\tilde{B}_k - I)\tilde{s}_k\|^2}{\|\tilde{s}_k\|^2} \\ &= \frac{\|\tilde{B}_k\tilde{s}_k\|^2 - 2\tilde{s}_k^T \tilde{B}_k \tilde{s}_k + \tilde{s}_k^T \tilde{s}_k}{\tilde{s}_k^T \tilde{s}_k} \\ &= \frac{\tilde{q}_k^2}{\cos \tilde{\theta}_k^2} - 2\tilde{q}_k + 1. \end{aligned}$$

由1.27右边收敛至0，我们可以得到

$$\lim_{k \rightarrow \infty} \frac{\|(B_k - G_*)s_k\|}{\|s_k\|} = 0.$$

收敛。1.17和1.4表示当 $\alpha_k = 1$ 将会满足在最优解附近Wolfe条件，因此收敛速率为超线性的。  $\square$

## 2 共轭梯度法

### 2.1 FR共轭梯度法

采用精确线性搜索的再开始共轭梯度法

算法：

给出初始点 $x_0$ ，容限 $\epsilon > 0$ .

Step 1: 令 $k = 0$ ，计算 $g_0 = g(x_0)$ .

Step 2: 若 $\|g_0\| \leq \epsilon$ ，停止迭代，输出 $x^* = x_0$ ；否则，令 $d_0 = -g_0$ .

Step 3: 一维搜索求 $\alpha_k$ ，使得

$$f(x_k + \alpha_k d_k) = \min_{\alpha} \{f(x_k + \alpha d_k) | \alpha \geq 0\}$$



Step 4: 令  $x_{k+1} = x_k + \alpha_k d_k, k := k + 1$ .

Step 5: 计算  $g_k = g(x_k)$ .

Step 6: 如果  $\|g_k\| \leq \epsilon$ , 停止迭代; 否则转Step 7.

Step 7: 若  $k = n$ , 令  $x_0 := x_k$ , 并转Step 1; 否则转Step 8.

Step 8: 计算

$$\beta = g_k^T g_k / g_{k-1}^T g_{k-1}, \quad d_k = -g_k + \beta d_{k-1}.$$

Step 9: 如果  $d_k^T g_k > 0$ , 令  $x_0 := x_k$ , 并转Step 1; 否则转Step 3.

## 2.2 FR共轭梯度法收敛性

**定理 2.1** (FR共轭梯度法全局收敛性定理). 假定在有界水平集  $\mathcal{L} = \{x \in R^n | f(x) \leq f(x_0)\}$  上  $f: R^n \rightarrow R$  连续可微, 那么采用

$$\beta = \frac{g_{k+1}^T g_{k+1}}{g_k^T g_k} \quad (2.1)$$

和精确线性搜索的FR共轭梯度法产生的序列  $\{x_k\}$  至少有一个聚点是驻点, 即

(1) 当  $\{x_k\}$  是有穷点列时, 其最后一个点  $x^*$  是  $f$  的驻点.

(2) 当  $\{x_k\}$  是无穷点列时, 它必有极限点, 且其任一极限点是  $f$  的驻点.

**证明.** (1) 当  $\{x_k\}$  是有穷点列时, 由算法的终止性条件可知, 其最后一点  $x^*$  满足  $\nabla f(x^*) = 0$ , 故  $x^*$  是  $f$  的驻点.

(2) 当  $\{x_k\}$  是无穷点列时, 则有  $\nabla f(x_k) \neq 0$ , 由于  $d_k = -g_k + \beta_{k-1} d_{k-1}$ , 故

$$g_k^T d_k = -\|g_k\|^2 + \beta_{k-1} g_k^T d_{k-1} = -\|g_k\|^2 < 0, \quad (2.2)$$

从而 $d_k$ 是下降方向,  $\{f(x_k)\}$ 是单调下降序列,  $\{x_k\} \subset \mathcal{L}$ , 所以 $\{x_k\}$ 是有界点列, 必有极限点.

设 $x^*$ 是 $\{x_k\}$ 的极限点, 则存在子列 $\{x_k\}_{K_1}$ 收敛到 $x^*$ , 这里 $K_1$ 是子序列的指标集. 由于 $\{x_k\}_{K_1} \subset \{x_k\}$ , 故 $\{f(x_k)\}_{K_1} \subset \{f(x_k)\}$ , 从而由 $f$ 的连续性可知, 对于 $k \in K_1$ , 有

$$f(x^*) = f\left(\lim_{k \rightarrow \infty} x_k\right) = \lim_{k \rightarrow \infty} f(x_k) = f^* \quad (2.3)$$

类似地,  $\{x_{k+1}\}$ 也是有界点列, 故存在子列 $\{x_{k+1}\}_{K_2}$ 收敛到 $x^*$ , 这里 $K_2$ 是 $\{x_{k+1}\}$ 的子序列的指标集, 并且

$$f(\bar{x}^*) = f\left(\lim_{k \rightarrow \infty} x_{k+1}\right) = \lim_{k \rightarrow \infty} f(x_{k+1}) = f^* \quad (2.4)$$

于是

$$f(\bar{x}^*) = f(x^*) = f^*. \quad (2.5)$$

现在用反证法证明 $\nabla f(x^*) = 0$ , 假定 $\nabla f(x^*) \neq 0$ , 则对于充分小的 $\alpha$ , 有

$$f(x^* + \alpha d^*) < f(x^*),$$

由于

$$f(x_{k+1}) = f(x_k + \alpha_k d_k) \leq f(x_k + \alpha d_k), \quad \forall \alpha > 0,$$

故对于 $k \in K_2$ , 令 $k \rightarrow \infty$ , 可得

$$f(\bar{x}^*) \leq f(x^* + \alpha d^*) < f(x^*), \quad (2.6)$$

这与2.5矛盾. 因此,  $\nabla f(x^*) = 0$ , 即 $x^*$ 是 $f$ 的驻点.  $\square$

### 2.3 FR共轭梯度法收敛速率

**假设 2.1.** (1).  $f \in C^3(R^n, R)$ , 即 $f: R^n \rightarrow R$ 三次连续可微。

(2) 设存在常数 $m > 0$ 和 $M > 0$ , 使得

$$m\|y\|^2 \leq y^T \nabla^2 f(x) y \leq M\|y\|^2, \quad \forall y \in R^n, x \in L,$$

其中 $L = \{x \in R^n | f(x) \leq f(x_0)\}$ 是有界水平集

**定理 2.2.** 假定假设2.1满足, 那么, 每 $r$ 步再开始的FR共轭梯度法产生的迭代点列 $\{x_k\}$   $n$ 步二阶收敛, 即存在常数 $c > 0$ , 使得

$$\limsup_{k \rightarrow \infty} \frac{\|x_{kr+n} - x^*\|}{\|x_{kr} - x^*\|^2} \leq c < \infty. \quad (2.7)$$

这个定理的证明分两步完成, 第一步证明2.3, 第二步证明2.4

**定理 2.3.** 设定理2.2的条件满足, 并设在每一个点 $x_{kr}$ 定义二次函数 $\hat{f}_{kr}$ 为

$$\hat{f}_{kr}(x) = f(x_{kr}) + \nabla f(x_{kr})^T (x - x_{kr}) + \frac{1}{2} (x - x_{kr})^T \nabla^2 f(x_{kr}) (x - x_{kr}). \quad (2.8)$$

设 $\psi_{\hat{f}_{kr}}$ 表示应用到 $\hat{f}_{kr}$ 上的共轭梯度法, 并且令 $d_{kr}^0 = d_{kr} = -\nabla f(x_{kr})$ .

又设

$$x_k^0 = x_{kr}, \quad x_{kr}^1 = \psi_{\hat{f}_{kr}}(x_{kr}^0), \dots, x_{kr}^n = \psi_{\hat{f}_{kr}}(x_{kr}^{n-1})$$

那么, 如果对于  $i = 0, 1, \dots, j(k) - 1$ ,

$$\|\alpha_{kr+i} d_{kr+i} - \alpha_{kr}^i d_{kr}^i\| = O(\|x_{kr} - x^*\|^2) \quad (2.9)$$

成立, 其中  $j(k)$  是小于等于  $n$  的整数, 满足

$$x_{kr}^{j(k)} = \bar{x}(\hat{f}_{kr}), \quad x_{kr}^{j(k)-1} \neq \bar{x}(\hat{f}_{kr}),$$

$\bar{x}(\hat{f}_{kr})$  表示函数  $\hat{f}_{kr}$  的极小点, 则再开始FR 共轭梯度法产生的点列满足2.7.

证明. 由于 $\hat{f}_{kr}$ 是二次正定函数, 共轭梯度法至多 $n$ 步达到其极小点. 由算法可知,

$$f(x_{k+1}) \leq f(x_k), \quad \forall k \quad (2.10)$$

故

$$f(x_{k+1}) - f(x^*) \leq f(x_k) - f(x^*) \quad (2.11)$$

又由Taylor 定理,

$$\begin{aligned} f(x_k) - f(x^*) &= \nabla f(x^*)^T (x_k - x^*) + (x_k - x^*)^T \nabla^2 f(\eta) (x_k - x^*) \\ &= (x_k - x^*)^T \nabla^2 f(\eta) (x_k - x^*) \end{aligned} \quad (2.12)$$

其中  $\eta = x_k + \alpha(x^* - x_k)$ ,  $\alpha \in (0, 1)$ . 再利用2.1, 则有

$$m \|x_k - x^*\|^2 \leq f(x_k) - f(x^*) \leq M \|x_k - x^*\|^2. \quad (2.13)$$

综合2.11和2.13, 得

$$\begin{aligned} m \|x_{k+1} - x^*\|^2 &\leq |f(x_{k+1}) - f(x^*)| \\ &\leq |f(x_k) - f(x^*)| \leq M \|x_k - x^*\|^2, \end{aligned}$$

即有

$$\|x_{k+1} - x^*\| \leq \sqrt{M/m} \|x_k - x^*\|. \quad (2.14)$$

因此,

$$\begin{aligned} \|x_{kr+n} - x^*\| &\leq (M/m)^{(n-j(k))/2} \|x_{kr+j(k)} - x^*\| \\ &\leq (M/m)^{n/2} \|x_{kr+j(k)} - x^*\| \end{aligned} \quad (2.15)$$

这表明, 为了证明结论2.7, 只要证明

$$\|x_{kr+j(k)} - x^*\| = O\left(\|x_{kr} - x^*\|^2\right) \quad (2.16)$$

由于

$$\|x_{kr+j(k)} - x^*\| \leq \|x_{kr+j(k)} - \bar{x}(\hat{f}_{kr})\| + \|\bar{x}(\hat{f}_{kr}) - x^*\|, \quad (2.17)$$

其中  $\bar{x}(\hat{f}_{kr})$  是  $\hat{f}_{kr}$  的极小点, 可以表示为

$$\bar{x}(\hat{f}_{kr}) = x_{kr} - [\nabla^2 f(x_{kr})]^{-1} \nabla f(x_{kr}),$$

但这恰恰是在  $x_{kr}$  点应用到  $f$  上的牛顿法, 这样

$$\|\bar{x}(\hat{f}_{kr}) - x^*\| = \|\hat{\phi}(x_{kr}) - x^*\|.$$

由于牛顿法二阶收敛, 便有

$$\|\hat{\phi}(x_{kr}) - x^*\| = O\left(\|x_{kr} - x^*\|^2\right). \quad (2.18)$$

因此, 从2.18, 2.17和2.18可知, 我们需要证明

$$\begin{aligned} \|x_{kr+j(k)} - \bar{x}(\hat{f}_{kr})\| &= \|x_{kr+j(k)} - x_{kr}^{j(k)}\| \\ &= O\left(\|x_{kr} - x^*\|^2\right). \end{aligned} \quad (2.19)$$

令  $x_{kr} = x_{kr}^0$ , 这样,

$$\begin{aligned}
\|x_{kr+j(k)} - x_{kr}^{j(k)}\| &= \left\| \sum_{i=0}^{j(k)-1} [(x_{kr+i+1} - x_{kr+i}) - (x_{kr}^{i+1} - x_{kr}^i)] \right\| \\
&= \left\| \sum_{i=0}^{j(k)-1} [\alpha_{kr+i} d_{kr+i} - \alpha_{kr}^i d_{kr}^i] \right\| \\
&\leq \sum_{i=0}^{j(k)-1} \|\alpha_{kr+i} d_{kr+i} - \alpha_{kr}^i d_{kr}^i\|.
\end{aligned} \tag{2.20}$$

从2.17、2.18、2.19和2.20可知,2.9意味着2.7成立.  $\square$

第二部分要证明2.9对于共轭梯度法成立.为此,我们先给出几个引理.

**引理 2.1.**

$$\alpha_k = \frac{\|g_k\|^2}{d_k^T \hat{B}_k d_k} \tag{2.21}$$

其中

$$\hat{B}_k = \int_0^1 \nabla^2 f(x_k + \xi \alpha_k d_k) d\xi. \tag{2.22}$$

证明.  $g_{k+1} = g_k + \alpha_k \hat{B}_k d_k$ , 由于  $g_{k+1}^T d_k = 0$ , 故有  $g_k^T d_k + \alpha_k d_k^T \hat{B}_k d_k = 0$ , 从而

$$\alpha_k = \frac{-g_k^T d_k}{d_k^T \hat{B}_k d_k} = \frac{\|g_k\|^2}{d_k^T \hat{B}_k d_k}.$$

$\square$

**引理 2.2.**

$$\|g_{k+1}\| \leq (1 + M/m) \|d_k\|. \tag{2.23}$$

证明. 由于  $d_{k+1} = -g_{k+1} + \beta_k d_k$  和  $g_{k+1}^T d_k = 0$ , 故

$$\|d_{k+1}\|^2 = \|g_{k+1}\|^2 + \beta_k^2 \|d_k\|^2. \tag{2.24}$$

这表明

$$\|g_{k+1}\| \leq \|d_{k+1}\| \tag{2.25}$$

利用2.1、2.21和2.25,

$$\alpha_k = \frac{\|g_k\|^2}{d_k^T \hat{B}_k d_k} \leq \frac{\|g_k\|^2}{m \|d_k\|^2} \leq \frac{1}{m}. \quad (2.26)$$

于是可得

$$\begin{aligned} \|g_{k+1}\| &\leq \|g_k\| + |\alpha_k| \|\hat{B}_k d_k\| \\ &\leq \|d_k\| + \frac{M}{m} \|d_k\| \\ &= \left(1 + \frac{M}{m}\right) \|d_k\|. \end{aligned}$$

□

**引理 2.3.** 对于 FR 公式,

$$\beta_k = 1 + \frac{(g_{k+1} + g_k)^T \hat{B}_k d_k}{d_k^T \hat{B}_k d_k}, \quad (2.27)$$

$$|\beta_k| \leq \left(1 + \frac{M}{m}\right)^2. \quad (2.28)$$

证明. 对于 FR 公式,

$$\begin{aligned} \beta_k &= \frac{\|g_{k+1}\|^2}{\|g_k\|^2} = \frac{g_{k+1}^T (g_{k+1} - g_k) + g_{k+1}^T g_k}{\|g_k\|^2} \\ &= \frac{g_{k+1}^T \hat{B}_k d_k}{d_k^T \hat{B}_k d_k} + \frac{g_{k+1}^T g_k}{\|g_k\|^2} \end{aligned} \quad (2.29)$$

由于

$$\begin{aligned} \frac{g_{k+1}^T g_k}{\|g_k\|^2} &= \frac{(g_k + \alpha_k \hat{B}_k d_k)^T g_k}{\|g_k\|^2} \\ &= 1 + \alpha_k \frac{g_k^T \hat{B}_k d_k}{\|g_k\|^2} \\ &= 1 + \frac{g_k^T \hat{B}_k d_k}{d_k^T \hat{B}_k d_k}, \end{aligned} \quad (2.30)$$

于是由2.29和2.30得

$$\beta_k = 1 + \frac{(g_{k+1} + g_k)^T \hat{B}_k d_k}{d_k^T \hat{B}_k d_k}$$

上式即为2.27。利用2.27, 2.25, 2.23有

$$\begin{aligned}
|\beta_k| &\leq 1 + \left| \frac{(g_{k+1} + g_k)^T \hat{B}_k d_k}{d_k^T \hat{B}_k d_k} \right| \\
&\leq 1 + \frac{(\|g_{k+1}\| + \|g_k\|) M \|d_k\|}{m \|d_k\|^2} \\
&\leq 1 + \frac{M}{m} \left( \frac{\|g_{k+1}\|}{\|d_k\|} + \frac{\|g_k\|}{\|d_k\|} \right) \\
&\leq 1 + \frac{M}{m} \left( 1 + \frac{M}{m} + 1 \right) \\
&\leq \left( 1 + \frac{M}{m} \right)^2.
\end{aligned}$$

□

**引理 2.4.**

$$\|g_k\| \leq M \|x_k - x^*\| \quad (2.31)$$

$$\|d_{k+1}\| \leq (1 + M/m)^2 \|d_k\| \quad (2.32)$$

证明.  $g_k = \nabla f(x^*) + \int_0^1 \nabla^2 f(x^* + \xi(x_k - x^*)) d\xi(x_k - x^*)$ , 即可得2.31.

又

$$d_{k+1} = -g_{k+1} + \beta_k d_k,$$

故

$$\|d_{k+1}\| \leq \|g_{k+1}\| + |\beta_k| \|d_k\|, \quad (2.33)$$

利用2.23, 2.28可得

$$\|d_{k+1}\| \leq (1 + M/m)^2 \|d_k\|.$$

□

**引理 2.5.**

$$\|\nabla^2 f(x_{k+i}) - \nabla^2 f(x_k)\| = O(\|d_k\|). \quad (2.34)$$

$$\|\hat{B}_{k+i} - \nabla^2 f(x_k)\| = O(\|d_k\|) \quad (2.35)$$

证明.

$$\|\nabla^2 f(x_{k+i}) - \nabla^2 f(x_k)\| \leq \sum_{l=0}^{i-1} \|\nabla^2 f(x_{k+l+1}) - \nabla^2 f(x_{k+l})\|$$

由于

$$\begin{aligned}
& \|\nabla^2 f(x_{k+l+1}) - \nabla^2 f(x_{k+l})\| \\
&= \|\nabla^2 f(x_{k+l} + \alpha_{k+l} d_{k+l}) - \nabla^2 f(x_{k+l})\| \\
&= \left\| \int_0^1 \nabla^3 f(x_{k+l} + \xi \alpha_{k+l} d_{k+l}) \alpha_{k+l} d_{k+l} d\xi \right\| \\
&\leq \sup_{\xi \in (0,1)} \|\nabla^3 f(x_{k+l} + \xi \alpha_{k+l} d_{k+l})\| |\alpha_{k+l}| \|d_{k+l}\|.
\end{aligned} \tag{2.36}$$

由于  $x_k \rightarrow x^*$ ,  $\nabla f(x^*) = 0$ ,  $f \in C^3$ , 故存在  $K_1$  和  $\bar{M}$ , 使得对于  $k \geq K_1$ ,  $\|\nabla^3 f(x_k)\| \leq \bar{M}$ . 又利用2.26和2.32,2.36可以写成

$$\|\nabla^2 f(x_{k+l+1}) - \nabla^2 f(x_{k+l})\| \leq \frac{\bar{M}}{m} \|d_{k+l}\| = O(\|d_k\|). \tag{2.37}$$

因此,

$$\|\nabla^2 f(x_{k+i}) - \nabla^2 f(x_k)\| = O(\|d_k\|).$$

此即2.34. 下面证明2.35.

$$\|\hat{B}_{k+i} - \nabla^2 f(x_k)\| \leq \|\hat{B}_{k+i} - \nabla^2 f(x_{k+i})\| + \|\nabla^2 f(x_{k+i}) - \nabla^2 f(x_k)\| \tag{2.38}$$

由于

$$\begin{aligned}
& \|\hat{B}_{k+i} - \nabla^2 f(x_{k+i})\| \\
&= \left\| \int_0^1 \nabla^2 f(x_{k+i} + \xi \alpha_{k+i} d_{k+i}) d\xi - \nabla^2 f(x_{k+i}) \right\| \\
&\leq \int_0^1 \|\nabla^2 f(x_{k+i} + \xi \alpha_{k+i} d_{k+i}) - \nabla^2 f(x_{k+i})\| d\xi, \\
&\quad \|\nabla^2 f(x_{k+i} + \xi \alpha_{k+i} d_{k+i}) - \nabla^2 f(x_{k+i})\| \\
&= \left\| \int_0^1 \nabla^3 f(x_{k+i} + \eta \alpha_{k+i} d_{k+i}) \alpha_{k+i} d_{k+i} d\eta \right\| \\
&\leq \sup_{\eta \in (0,1)} \|\nabla^3 f(x_{k+i} + \eta \alpha_{k+i} d_{k+i})\| |\alpha_{k+i}| \|d_{k+i}\| \\
&\leq \frac{M}{m} \|d_{k+i}\|,
\end{aligned} \tag{2.40}$$

因此,利用2.32,

$$\|\hat{B}_{k+i} - \nabla^2 f(x_k)\| \leq \frac{\bar{M}}{m} \|d_{k+i}\| = O(\|d_k\|). \tag{2.41}$$

于是, 由2.38,2.34和2.41得2.35.  $\square$



引理 2.6. 对于FR公式, 有

$$\begin{aligned} \|d_{k+i+1} - d_k^{i+1}\| = & O_1(\|d_{k+i} - d_k^i\|) + O_2(\|g_{k+i+1} - g_k^{i+1}\|) \\ & + O_3(\|g_{k+i} - g_k^i\|) + O_4(\|d_k\|^2). \end{aligned} \quad (2.42)$$

引理 2.7.

$$\begin{aligned} \|g_{k+i+1} - g_k^{i+1}\| \leq & \|g_{k+i} - g_k^i\| + O(\|d_k\|^2) \\ & + M\|\alpha_{k+i}d_{k+i} - \alpha_k^i d_k^i\|. \end{aligned} \quad (2.43)$$

证明.

$$\begin{aligned} \|g_{k+i+1} - g_k^{i+1}\| &= \|g_{k+i} + \alpha_{k+i}\hat{B}_{k+i}d_{k+i} - g_k^i - \alpha_k^i \nabla^2 f(x_k) d_k^i\| \\ &\leq \|g_{k+i} - g_k^i\| + \left\| \left( \nabla^2 f(x_k) - \hat{B}_{k+i} \right) \alpha_k^i d_k^i \right\| \\ &\quad + \left\| \hat{B}_{k+i} (\alpha_k^i d_k^i - \alpha_{k+i} d_{k+i}) \right\| \\ &\leq \|g_{k+i} - g_k^i\| + \frac{1}{m} \left\| \nabla^2 f(x_k) - \hat{B}_{k+i} \right\| \|d_k^i\| \\ &\quad + M \|\alpha_k^i d_k^i - \alpha_{k+i} d_{k+i}\| \\ &\leq \|g_{k+i} - g_k^i\| + O(\|d_k\|^2) + M \|\alpha_k^i d_k^i - \alpha_{k+i} d_{k+i}\|. \end{aligned}$$

□

引理 2.8.

$$\begin{aligned} \|\alpha_{k+i}d_{k+i} - \alpha_k^i d_k^i\| = & O_1(\|g_{k+i} - g_k^i\|) + O_2(\|d_{k+i} - d_k^i\|) \\ & + O_3(\|d_k\|^2). \end{aligned} \quad (2.44)$$

证明. 由2.21可知

$$\begin{aligned}
\|\alpha_{k+i}d_{k+i} - \alpha_k^i d_k^i\| &= \left\| \frac{\|g_{k+i}\|^2 d_{k+i}}{d_{k+i}^T \hat{B}_{k+i} d_{k+i}} - \frac{\|g_k^i\|^2 d_k^i}{d_k^i{}^T \nabla^2 f(x_k) d_k^i} \right\| \\
&= \frac{1}{c_{k+i}} \left\| \|g_{k+i}\|^2 \left( d_k^i{}^T \nabla^2 f(x_k) d_k^i \right) d_{k+i} - \|g_k^i\|^2 \left( d_{k+i}^T \hat{B}_{k+i} d_{k+i} \right) d_k^i \right\| \\
&\leq \frac{1}{c_{k+i}} \{ \| (g_{k+i}^T (g_{k+i} - g_k^i)) (d_k^i \nabla^2 f(x_k) d_k^i) d_{k+i} \| \\
&\quad + \| (g_{k+i}^T g_k^i) ((d_k^i - d_{k+i})^T \nabla^2 f(x_k) d_k^i) d_{k+i} \| \\
&\quad + \| ((g_{k+i} - g_k^i)^T g_k^i) (d_{k+i}^T \nabla^2 f(x_k) d_k^i) d_{k+i} \| \\
&\quad + \| \|g_k^i\|^2 (d_{k+i}^T \nabla^2 f(x_k) (d_k^i - d_{k+i})) d_{k+i} \| \\
&\quad + \| \|g_k^i\|^2 (d_{k+i}^T \nabla^2 f(x_k) d_{k+i}) (d_{k+i} - d_k^i) \| \\
&\quad + \| \|g_k^i\|^2 (d_{k+i}^T (\nabla^2 f(x_k) - \hat{B}_{k+i}) d_{k+i}) d_k^i \| \}.
\end{aligned} \tag{2.45}$$

注意到

$$\frac{1}{c_{k+i}} \leq \frac{1}{m^2 \|d_{k+i}\|^2 \|d_k^i\|^2}$$

利用2.25,2.23,2.35, 便得所需要的结果2.44.  $\square$

**定理 2.4.** 设2.2的条件满足, 那么,

$$d_k \rightarrow 0, \tag{2.46}$$

$$\|\alpha_{kr+i}d_{kr+i} - \alpha_{kr}^i d_{kr}^i\| = O\left(\|d_{kr}\|^2\right), i = 0, 1, \dots, j(k) - 1, \tag{2.47}$$

$$\|\alpha_{kr+i}d_{kr+i} - \alpha_{kr}^i d_{kr}^i\| = O\left(\|x_{kr} - x^*\|^2\right), i = 0, 1, \dots, j(k) - 1, \tag{2.48}$$

其中, 对于所有 $k$ 和 $r \geq n$ ,  $d_{kr} = -g_{kr}$ .

证明. 由2.32,  $\|d_{k+1}\| \leq (1 + M/m)^2 \|d_k\|$ , 故

$$\|d_{kr+i}\| \leq [(1 + M/m)^2]^i \|d_{kr}\|, \quad i = 0, 1, \dots, j(k) - 1.$$

由于算法收敛, 2.31意味着 $g_k \rightarrow 0$ , 因此,  $d_{kr} \rightarrow 0$ , 由2.32, 有 $d_k \rightarrow 0$ , 2.46得到. 为了证明2.47, 我们用归纳法证明: 对于  $i = 0, 1, \dots, j(k/r) - 1$ , 以及  $k$  是  $r$  的倍数, 有

$$\|g_{k+i} - g_k^i\| = O\left(\|d_k\|^2\right), \tag{2.49}$$

$$\|d_{k+i} - d_k^i\| = O\left(\|d_k\|^2\right), \quad (2.50)$$

$$\|\alpha_{k+i}d_{k+i} - \alpha_k^i d_k^i\| = O\left(\|d_k\|^2\right) \quad (2.51)$$

首先, 对于  $i = 0$ , 由于  $g_k = g_k^0, d_k = d_k^0$  和 2.44, 可知 2.49-2.51 成立. 今假定 2.49-2.51 对于  $i$  成立, 我们证明它们对于  $i + 1$  也成立. 由 2.43 和归纳法假设,

$$\begin{aligned} \|g_{k+i+1} - g_k^{i+1}\| &\leq \|g_{k+i} - g_k^i\| + O\left(\|d_k\|^2\right) \\ &\quad + M \|\alpha_{k+i}d_{k+i} - \alpha_k^i d_k^i\| \\ &= O\left(\|d_k\|^2\right). \end{aligned} \quad (2.52)$$

由 2.42, 对于 FR 公式,

$$\begin{aligned} \|d_{k+i+1} - d_k^{i+1}\| &= O_1\left(\|d_{k+i} - d_k^i\|\right) + O_2\left(\|g_{k+i+1} - g_k^{i+1}\|\right) \\ &\quad + O_3\left(\|g_{k+i} - g_k^i\|\right) + O_4\left(\|d_k\|^2\right). \end{aligned}$$

这样, 由归纳法假设, 我们有

$$\|d_{k+i+1} - d_k^{i+1}\| = O\left(\|d_k\|^2\right). \quad (2.53)$$

最后, 利用 2.44, 2.52 和归纳法假设, 有

$$\begin{aligned} &\|\alpha_{k+i+1}d_{k+i+1} - \alpha_k^{i+1}d_k^{i+1}\| \\ &= O_1\left(\|g_{k+i+1} - g_k^{i+1}\|\right) + O_2\left(\|d_{k+i+1} - d_k^{i+1}\|\right) + O_3\left(\|d_k\|^2\right) \\ &= O\left(\|d_k\|^2\right). \end{aligned} \quad (2.54)$$

这样 2.49-2.51 证得, 从而, 2.47 得到. 由 2.47, 并注意到  $d_{kr} = -g_{kr}$  和  $\|g_{kr}\| \leq M\|x_{kr} - x^*\|$ , 即可得到 2.48. 而这等价于 2.9. 综合定理 4.3.8 和定理 4.3.17, 我们便得到再开始共轭梯度法的  $n$  步二阶收敛定理 4.3.7.  $\square$

## 3 信赖域

### 3.1 信赖域算法

信赖域子问题

$$\min_{d \in \mathbb{R}^n} m_k(d) = f(x_k) + \nabla f(x_k)^T d + \frac{1}{2} d^T B_k d, \quad \text{s.t.} \quad \|d\| \leq \Delta_k. \quad (3.1)$$

---

**Algorithm 1** 信赖域算法

---

给定最大半径 $\Delta_{max}$ ，初始半径 $\Delta_0$ ，初始点 $x_0, k \leftarrow 0$ .

给定参数 $0 \leq \eta < \bar{\rho}_1 < \bar{\rho}_2 < 1, \gamma_1 < 1 < \gamma_2$ .

**while** 未达到收敛准则 **do**

    计算信赖域子问题3.1得到迭代方向 $d_k$ .

    根据 $\rho_k = \frac{f(x_k) - f(x_k + d_k)}{m_k(0) - m_k(d_k)}$ 计算下降率 $\rho_k$

**if**  $\rho_k < \bar{\rho}_1$  **then** 缩小信赖域半径:  $\Delta_{k+1} = \gamma_1 \Delta_k$ .

**else**

**if**  $\rho_k > \bar{\rho}_2$  以及  $\|d_k\| = \Delta_k$  **then**

            扩大信赖域半径:  $\Delta_{k+1} = \min \{\gamma_2 \Delta_k, \Delta_{max}\}$ .

**else**

            信赖域半径不变:  $\Delta_{k+1} = \Delta_k$ .

**if**  $\rho_k > \eta$  **then**

        更新 $x_{k+1} = x_k + d_k$ .

**else**

$x_{k+1} = x_k$ .

$k \rightarrow k + 1$ .

---

在此章节，我们取 $\bar{\rho}_1 = \frac{1}{4}$ ， $\bar{\rho}_2 = \frac{3}{4}$ ， $\gamma_1 = \frac{1}{4}$ ， $\gamma_2 = 2$

### 3.2 信赖域算法收敛性

现在介绍信赖域算法的全局收敛性。回顾信赖域算法6.8，我们引入了一个参数 $\eta$ 来确定是否应该更新迭代点。这分为两种情况：当 $\eta = 0$ 时，只要原目标函数有下降量就接受信赖域迭代步的更新；当 $\eta > 0$ 时，只有当改善量 $\rho_k$ 达到一定程度时再进行更新。在这两种情况下得到的收敛性结果是不同的，我们分别介绍这两种结果。

#### 3.2.1 信赖域算法全局收敛性

在 $\eta = 0$ 的条件下有如下收敛性定理：

**定理 3.1** (信赖域算法全局收敛性1). 设近似海瑟矩阵 $B_k$ 有界, 即 $\|B_k\|_2 \leq M, \forall k$ ,  $f(x)$ 在下水平集 $\mathcal{L} = \{x | f(x) \leq f(x_0)\}$ 上有下界, 且 $\nabla f(x)$ 在 $\mathcal{L}$ 的一个开邻域内 $Lip$ 连续. 若 $d_k$ 为信赖域子问题的近似解且满足

$$m_k(0) - m_k(d_k) \geq c_1 \|\nabla f(x_k)\| \min \left\{ \Delta_k, \frac{\|\nabla f(x_k)\|}{\|B_k\|_2} \right\}, \quad (3.2)$$

其中 $c_1 \in (0, 1]$ . 算法3.1选取参数 $\eta = 0$ , 则

$$\liminf_{k \rightarrow \infty} \|\nabla f(x_k)\| = 0, \quad (3.3)$$

即 $x_k$ 的聚点中包含稳定点.

证明. 通过对比 $\rho_k$ 公式可以得到

$$\begin{aligned} |\rho_k - 1| &= \left| \frac{(f(x_k) - f(x_k + d_k)) - (m_k(0) - m_k(d_k))}{m_k(0) - m_k(d_k)} \right| \\ &= \left| \frac{m_k(d_k) - f(x_k + d_k)}{m_k(0) - m_k(d_k)} \right| \end{aligned}$$

由Taylor公式可以得到

$$f(x_k + d_k) = f(x_k) + \nabla f(x_k)^T d_k + \int_0^1 [\nabla f(x_k + td_k) - \nabla f(x_k)]^T d_k dt,$$

存在某个 $t \in (0, 1)$ , 使得

$$\begin{aligned} |m_k(d_k) - f(x_k + d_k)| &= \left| \frac{1}{2} d_k^T B_k d_k - \int_0^1 [\nabla f(x_k + td_k) - \nabla f(x_k)]^T d_k dt \right| \\ &\leq (M/2) \|d_k\|^2 + L \|d_k\|^2, \end{aligned} \quad (3.4)$$

其中,  $L$ 是 $\nabla f$ 在集合 $S(R_0) = \{x | \|x - y\| < R_0, y \in S\}$ 的Lipschitz常数, 假设 $\|d_k\| \leq R_0$ .

反证法: 假设存在 $\epsilon > 0, K \in \mathbb{N}^*$ 使得

$$\|\nabla f(x_k)\| \geq \epsilon, \quad \forall k \geq K. \quad (3.5)$$

因此, 对 $k \geq K$ , 有

$$m_k(0) - m_k(d_k) \geq c_1 \|\nabla f(x_k)\| \min \left( \Delta_k, \frac{\|\nabla f(x_k)\|}{\|B_k\|} \right) \geq c_1 \epsilon \min \left( \Delta_k, \frac{\epsilon}{M} \right) \quad (3.6)$$

对于 $\gamma \geq 1$ , 我们有

$$\|d_k\| \leq \gamma \Delta_k, \quad (3.7)$$

由3.7,3.4,3.6, 我们有

$$|\rho_k - 1| \leq \frac{\gamma^2 \Delta_k^2 (M/2 + L)}{c_1 \epsilon \min(\Delta_k, \epsilon/M)}. \quad (3.8)$$

为了给出当 $k$ 足够大时 $\Delta$ 的一个上界 $\bar{\Delta}$ , 令

$$\bar{\Delta} = \min \left( \frac{1}{2} \frac{c_1 \epsilon}{\gamma^2 (M/2 + L)}, \frac{R_0}{\gamma} \right) \quad (3.9)$$

由于 $c_1 \leq 1, \gamma \geq 1$ , 我们有 $\bar{\Delta} \leq \epsilon/M$ , 并且 $\Delta_k \in [0, \bar{\Delta}], \forall k$ , 因此 $\min(\Delta_k, \epsilon/M) = \Delta_k$ .

$$|\rho_k - 1| \leq \frac{\gamma^2 \Delta_k^2 (M/2 + L)}{c_1 \epsilon \Delta_k} = \frac{\gamma^2 \Delta_k (M/2 + L)}{c_1 \epsilon} \leq \frac{\gamma^2 \bar{\Delta} (M/2 + L)}{c_1 \epsilon} \leq \frac{1}{2}. \quad (3.10)$$

因此,  $\rho_k > \frac{1}{4}$ . 由3.1可知,  $\Delta_{k+1} \leq \Delta_k$ 仅当 $\Delta_k \leq \bar{\Delta}$ 成立。因此可以得到

$$\Delta_k \geq \min(\Delta_K, \bar{\Delta}/4) \quad \forall k \geq K. \quad (3.11)$$

假设存在一个无限子列 $\mathcal{K}$ 使得 $\rho_k \geq \frac{1}{4}, \forall k \in \mathcal{K}$ . 对 $k \in \mathcal{K}, k \geq K$ 我们由3.6有

$$\begin{aligned} f(x_k) - f(x_{k+1}) &= f(x_k) - f(x_k + d_k) \\ &\geq \frac{1}{4} [m_k(0) - m_k(d_k)] \\ &\geq \frac{1}{4} c_1 \epsilon \min(\Delta_k, \epsilon/\beta). \end{aligned}$$

由于 $f$ 是下有界的, 则会有

$$\lim_{k \in \mathcal{K}, k \rightarrow \infty} \Delta_k = 0,$$

这与3.11矛盾因此不存在这样的子列, 所以必有3.3成立。  $\square$

**定理 3.2** (信赖域算法全局收敛性2). 在3.1的条件下, 若3.1选取参数 $\eta > 0$ , 且信赖域子问题近似解 $d_k$ 满足3.2, 则

$$\lim_{k \rightarrow \infty} \|\nabla f(x_k)\| = 0. \quad (3.12)$$

证明. 取正整数 $m$ 使得 $\nabla f(x_k) \neq 0$ . 令 $\beta_1$ 为 $\nabla f$ 在集合 $S(R_0)$ 的Lipschitz常数, 则我们有

$$\|\nabla f(x) - \nabla f(x_m)\| \leq \beta_1 \|x - x_m\|, \quad \forall x \in S(R_0)$$

定义

$$\epsilon = \frac{1}{2} \|\nabla f(x_m)\|, \quad R = \min \left( \frac{\epsilon}{\beta_1}, R_0 \right).$$

令球

$$\mathcal{B}(x_m, R) = \{x \mid \|x - x_m\| \leq R\}$$

包含在  $S(R_0)$ , 因此我们有

$$x \in \mathcal{B}(x_m, R) \Rightarrow \|\nabla f(x)\| \geq \|\nabla f(x_m)\| - \|\nabla f(x) - \nabla f(x_m)\| \geq \frac{1}{2} \|\nabla f(x_m)\| = \epsilon.$$

若  $\{x_k\}_{k \geq m}$  均在球  $\mathcal{B}(x_m, R)$  内, 我们有  $\|\nabla f(x_k)\| \geq \epsilon > 0, \forall k \geq m$ . 而这种情况不可能发生, 因此序列  $\{x_k\}_{k \geq m}$  会离开  $\mathcal{B}(x_m, R)$ .

取  $l \geq m$ , 使得  $x_{l+1}$  是第一个迭代到球  $\mathcal{B}(x_m, R)$  外的. 由于  $\|\nabla f(x_k)\| \geq \epsilon, k = m, m+1, \dots, l$ , 根据3.6可知

$$\begin{aligned} f(x_m) - f(x_{l+1}) &= \sum_{k=m}^l f(x_k) - f(x_{k+1}) \\ &\geq \sum_{k=m, x_k \neq x_{k+1}}^l \eta[m_k(0) - m_k(d_k)] \\ &\geq \sum_{k=m, x_k \neq x_{k+1}}^l \eta c_1 \epsilon \min \left( \Delta_k, \frac{\epsilon}{M} \right) \end{aligned}$$

若  $\Delta_k \leq \epsilon/M, k = m, m+1, \dots, l$ , 则

$$f(x_m) - f(x_{l+1}) \geq \eta c_1 \epsilon \sum_{k=m, x_k \neq x_{k+1}}^l \Delta_k \geq \eta c_1 \epsilon R = \eta c_1 \epsilon \min \left( \frac{\epsilon}{\beta_1}, R_0 \right). \quad (3.13)$$

否则, 我们有  $\Delta_k > \epsilon/\beta, k = m, m+1, \dots, l$ , 且

$$f(x_m) - f(x_{l+1}) \geq \eta c_1 \epsilon \frac{\epsilon}{M}. \quad (3.14)$$

由于序列  $\{f(x_k)\}_{k=0}^\infty$  是单调递减且有下界, 我们有

$$f(x_k) \downarrow f^* \quad (3.15)$$

因此由3.13和3.14, 我们可以得到

$$\begin{aligned} f(x_m) - f^* &\geq f(x_m) - f(x_{l+1}) \\ &\geq \eta c_1 \epsilon \min \left( \frac{\epsilon}{M}, \frac{\epsilon}{\beta_1}, R_0 \right) \\ &= \frac{1}{2} \eta c_1 \|\nabla f(x_m)\| \min \left( \frac{\|\nabla f(x_m)\|}{2M}, \frac{\|\nabla f(x_m)\|}{2\beta_1}, R_0 \right) > 0. \end{aligned}$$

由于  $f(x_m) - f^* \downarrow 0$ , 我们由  $\nabla f(x_m) \rightarrow 0$ . □

### 3.3 信赖域算法的局部收敛性与超线性收敛速度

**定理 3.3.** 设 $f$ 是二阶可微, 海瑟矩阵 $\nabla^2 f(x)$ 在最优解 $x^*$ 附近 $Lipschitz$ 连续, 对于迭代 $x_{k+1} = x_k + d_k$ , 其中 $d_k^N = -\nabla^2 f(x_k)^{-1} \nabla f(x_k)$ , 那么

(1) 若起始点 $x_0$ 充分靠近 $x^*$ , 则迭代序列收敛至 $x^*$

(2)  $\{x_k\}$ 具有二阶收敛速度

(3)  $\{\|\nabla f(x_k)\|\}$ 二阶收敛至0

**定理 3.4.** 设 $f(x)$ 在最优点 $x = x^*$ 的一个邻域内二阶连续可微, 且 $\nabla f(x)$   $Lip$ 连续, 在最优点 $x^*$ 处二阶充分条件成立, 即 $\nabla^2 f(x) \succ 0$ . 若迭代点列 $\{x_k\}$ 收敛到 $x^*$ , 且在迭代中选取 $B_k$ 为海瑟矩阵 $\nabla^2 f(x_k)$ , 则对充分大的 $k$ , 任意满足3.2的信赖域子问题算法产生的迭代方向 $d_k$ 均满足

$$\|d_k - d_k^N\| = o(\|d_k^N\|), \quad (3.16)$$

其中 $d_k^N$ 为第 $k$ 步迭代的牛顿方向且满足假设 $\|d_k^N\| \leq \frac{\Delta_k}{2}$  进一步地, 信赖域算法产生的迭代序列 $\{x_k\}$ 具有超线性收敛速度。

证明. 若对足够大的 $k$ 有 $\|d_k^N\| \leq \frac{1}{2}\Delta_k$ ,  $\|d_k\| \leq \Delta_k$ , 那么在最优点附近的迭代步肯定满足3.16。

对足够大的 $k$ 找到 $m_k(0) - m_k(d_k)$ 的一个下界。假设 $k$ 足够大是得 $\|d_k^N\| \leq o(\|d_k^N\|)$ 。当 $\|d_k\| \leq \|d_k^N\| + o(\|d_k^N\|) \leq 2\|d_k^N\|$ , 而若 $\|d_k^N\| > \frac{1}{2}\Delta_k$ , 那么我们有 $\|d_k\| \leq \Delta_k < 2\|d_k^N\|$ 。在两种情况下, 我们都有

$$\|d_k\| \leq 2\|d_k^N\| \leq 2\|\nabla^2 f(x_k)^{-1}\| \|\nabla f(x_k)\|$$

因此 $\|\nabla f(x_k)\| \geq \frac{1}{2}\|d_k\| / \|\nabla^2 f(x_k)^{-1}\|$ 。



由3.2可知

$$\begin{aligned}
& m_k(0) - m_k(d_k) \\
& \geq c_1 \|\nabla f(x_k)\| \min \left( \Delta_k, \frac{\|\nabla f(x_k)\|}{\|\nabla^2 f(x_k)\|} \right) \\
& \geq c_1 \frac{\|d_k\|}{2\|\nabla^2 f(x_k)^{-1}\|} \min \left( \|d_k\|, \frac{\|d_k\|}{2\|\nabla^2 f(x_k)^{-1}\| \|\nabla^2 f(x_k)\|} \right) \\
& = c_1 \frac{\|d_k\|^2}{4\|\nabla^2 f(x_k)^{-1}\|^2 \|\nabla^2 f(x_k)\|}
\end{aligned}$$

由于 $x_k \rightarrow x^*$ , 利用 $\nabla^2 f(x)$ 的连续性与 $\nabla^2 f(x^*)$ 的正定性可以得到当 $k$ 足够大时,

$$\frac{c_1}{4\|\nabla^2 f(x_k)^{-1}\|^2 \|\nabla^2 f(x_k)\|} \geq \frac{c_1}{8\|\nabla^2 f(x_k)^{-1}\|^2 \|\nabla^2 f(x^*)\|} = c_3$$

其中 $c_3 > 0$ , 因此对足够大的 $k$ 我们有

$$m_k(0) - m_k(d_k) \geq c_3 \|d_k\|^2. \quad (3.17)$$

由 $\nabla^2 f(x)$ 在 $x^*$ 附近的Lipschitz连续性可得

$$\begin{aligned}
& |(f(x_k) - f(x_k + d_k)) - (m_k(0) - m_k(d_k))| \\
& = \frac{1}{2} d_k^T \nabla^2 f(x_k) d_k - \frac{1}{2} \int_0^1 d_k^T \nabla^2 f(x_k + t d_k) d_k dt \\
& \leq \frac{L}{4} \|d_k\|^3.
\end{aligned}$$

其中 $L > 0$ 是 $\nabla^2 f(\cdot)$ Lip常数。因此由 $\rho_k$ 的定义我们可以得到对足够大的 $k$ , 有

$$|\rho_k - 1| \leq \frac{\|d_k\|^3 (L/4)}{c_3 \|d_k\|^2} = \frac{L}{4c_3} \|d_k\| \leq \frac{L}{4c_3} \Delta_k. \quad (3.18)$$

若信赖域半径下降则仅当 $\rho_k < \frac{1}{4}$ , 那么由3.18可知 $\{\Delta_k\}$ 是远离0的。由于 $x_k \rightarrow x^*$ , 我们有 $\|d_k^N\| \rightarrow 0$ , 所以由3.16可知 $\|d_k\| \rightarrow 0$ . 因此当 $k$ 足够大时信赖域半径的约束终将失效, 且算法产生的迭代方向将会越来越接近牛顿方向, 那么 $\|d_k^N\| \leq \Delta_k$ 总能被满足。

为了证明超线性收敛性, 我们利用3.3, 那么我们有

$$\|x_k + d_k^N - x^*\| = o(\|x_k - x^*\|^2),$$

因此 $\|d_k^N\| = \mathcal{O}(\|x_k - x^*\|)$ .

由3.16可知

$$\begin{aligned} & \|x_k + d_k - x^*\| \\ & \leq \|x_k + d_k^N - x^*\| + \|d_k^N - d_k\| = o(\|x_k - x^*\|^2) + o(\|d_k^N\|) = o(\|x_k - x^*\|), \end{aligned}$$

这说明信赖域算法是超线性收敛的。

□